**Laporan Praktikum 2: Praproses Data**

*Dataset: House Prices - Advanced Regression Techniques (Kaggle)*

Nama : Evina Fitriyani

NRP : 5054251013

## 1. Deskripsi Dataset

Dataset yang digunakan pada praktikum ini adalah House Prices - Advanced Regression Techniques dari Kaggle, khususnya file train.csv yang berisi 1460 baris dan 81 kolom informasi rumah, mulai dari ukuran bangunan, tahun dibangun, kondisi, sampai harga jual (SalePrice) sebagai atribut target.

## 2. Langkah-Langkah Praproses

- Import dataset dan pengecekan struktur data awal (head, shape, info).
- Pembersihan data: identifikasi missing value, penghapusan kolom dengan missing di atas 50%, dan pengisian sisa missing value.
- Deteksi outlier dengan boxplot dan penanganannya menggunakan metode IQR capping.
- Transformasi data: standarisasi atribut numerik dan one-hot encoding atribut kategorikal.
- Reduksi dimensi: analisis korelasi antar atribut dan Principal Component Analysis (PCA).

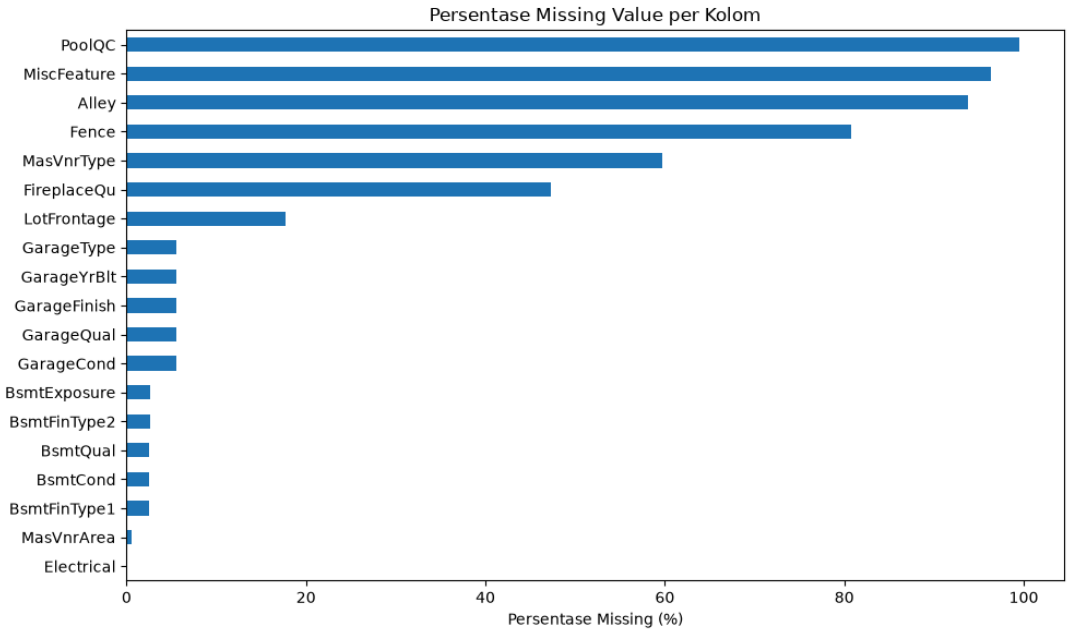
## 3. Hasil Setiap Tahapan Praproses

### 3.1 Pembersihan Data

Dari 81 kolom awal, ditemukan 19 kolom yang memiliki missing value, dengan persentase mulai dari 0,07% (Electrical) hingga 99,52% (PoolQC). Rincian missing value per kolom ditampilkan pada tabel berikut.

| Kolom | Jumlah Missing | Persentase (%) |
|---|---|---|
| PoolQC | 1453 | 99.52 |
| MiscFeature | 1406 | 96.30 |
| Alley | 1369 | 93.77 |
| Fence | 1179 | 80.75 |
| MasVnrType | 872 | 59.73 |
| FireplaceQu | 690 | 47.26 |
| LotFrontage | 259 | 17.74 |
| GarageType | 81 | 5.55 |
| GarageYrBlt | 81 | 5.55 |
| GarageFinish | 81 | 5.55 |
| GarageQual | 81 | 5.55 |
| GarageCond | 81 | 5.55 |
| BsmtExposure | 38 | 2.60 |

| Kolom | Jumlah Missing | Persentase (%) |
|---|---|---|
| PoolQC | 1453 | 99.52 |
| MiscFeature | 1406 | 96.30 |
| BsmtFinType2 | 38 | 2.60 |
| BsmtQual | 37 | 2.53 |
| BsmtCond | 37 | 2.53 |
| BsmtFinType1 | 37 | 2.53 |
| MasVnrArea | 8 | 0.55 |
| Electrical | 1 | 0.07 |



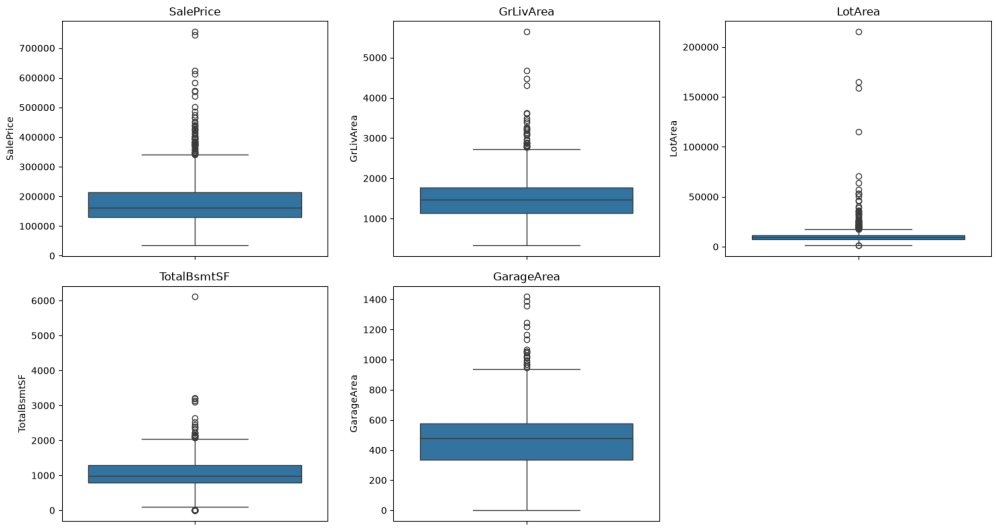

*Gambar 1. Persentase missing value per kolom*

Kolom dengan missing value di atas 50% (PoolQC, MiscFeature, Alley, Fence, MasVnrType) dihapus karena informasinya terlalu banyak yang kosong sehingga berisiko menimbulkan bias jika dipaksa diisi. Shape data setelah penghapusan kolom menjadi (1460, 76).

Sisa 14 kolom yang masih memiliki missing value ditangani dengan strategi berbeda sesuai tipe datanya: kolom numerik diisi menggunakan median (lebih tahan terhadap outlier dibanding mean), sedangkan kolom kategorikal diisi menggunakan modus (nilai yang paling sering muncul). Setelah tahap ini, total missing value pada dataset menjadi 0.

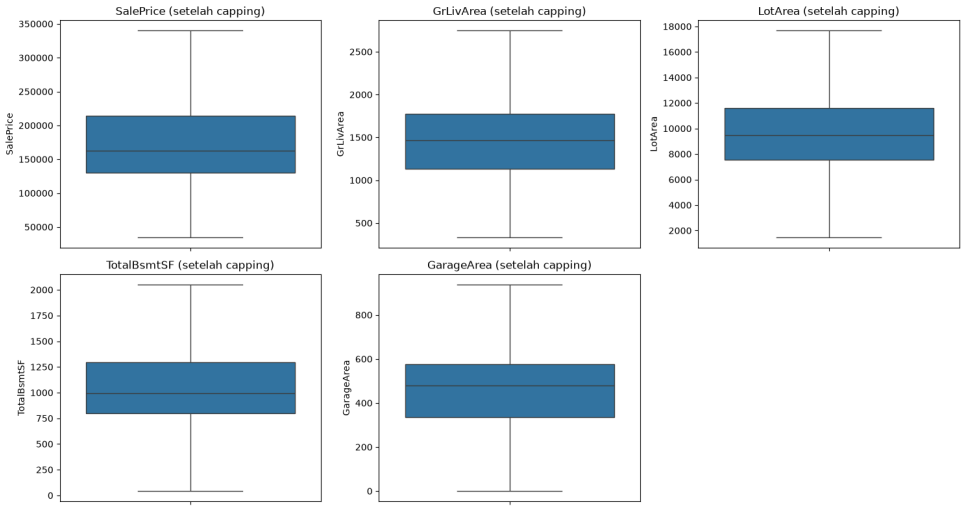
3.2 Deteksi dan Penanganan Outlier

Deteksi outlier dilakukan menggunakan boxplot pada lima atribut numerik penting: SalePrice, GrLivArea, LotArea, TotalBsmtSF, dan GarageArea.




*Gambar 2. Boxplot sebelum penanganan outlier*

Terlihat cukup banyak titik di luar whisker pada kelima atribut tersebut, terutama pada LotArea yang rentangnya mencapai ratusan ribu. Outlier ini tidak dihapus karena nilai ekstrem tersebut kemungkinan besar merupakan rumah yang memang berukuran besar atau bernilai jual tinggi secara wajar, bukan kesalahan input data. Oleh karena itu, penanganan outlier dilakukan dengan metode IQR capping, yaitu membatasi nilai yang melebihi batas atas/bawah IQR tanpa menghapus barisnya.




*Gambar 3. Boxplot setelah capping*

Setelah capping, sebaran data pada kelima atribut terlihat lebih rapat dan whisker menjadi lebih pendek, menandakan nilai ekstrem sudah terkendali tanpa kehilangan baris data. Dataset hasil tahap cleaning ini (shape 1460 x 76) disimpan sebagai file csv akhir yang dikumpulkan.

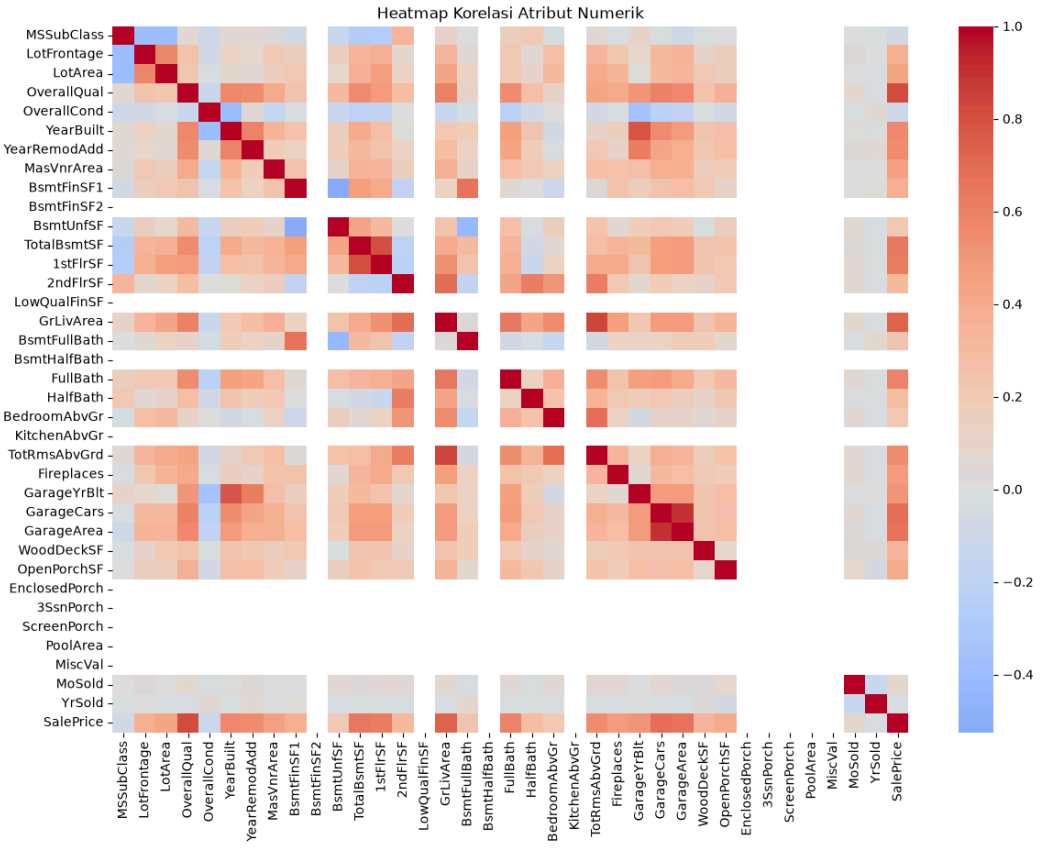
### 3.3 Transformasi Data

Atribut numerik (kecuali SalePrice yang merupakan target) distandarisasi menggunakan StandardScaler agar seluruh fitur memiliki skala yang sebanding. Untuk atribut kategorikal, dilakukan one-hot encoding pada 38 kolom kategorikal, yang membuat jumlah kolom bertambah dari 76 menjadi 235.

| Tahap | Jumlah Baris | Jumlah Kolom |
|---|---|---|
| Sebelum encoding | 1460 | 76 |
| Setelah one-hot encoding | 1460 | 235 |

3.4 Reduksi Dimensi

Analisis korelasi dilakukan pada atribut numerik untuk mengidentifikasi pasangan atribut yang informasinya saling tumpang tindih.



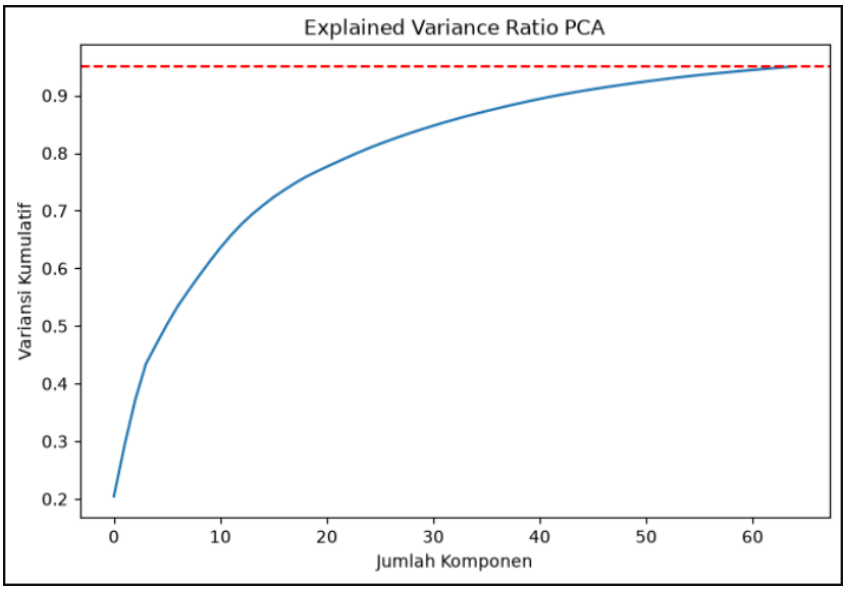

*Gambar 4. Heatmap korelasi atribut numerik*

Ditemukan empat pasangan atribut dengan korelasi di atas 0,8, seperti ditunjukkan pada tabel berikut.

| Atribut 1 | Atribut 2 | Korelasi |
|---|---|---|
| 1stFlrSF | TotalBsmtSF | 0.81 |
| TotRmsAbvGrd | GrLivArea | 0.84 |
| GarageArea | GarageCars | 0.89 |
| SalePrice | OverallQual | 0.82 |

Tiga pasangan pertama (1stFlrSF, TotRmsAbvGrd, GarageArea) dibuang salah satunya karena informasinya redundan dengan atribut pasangannya. Pasangan SalePrice-OverallQual tetap dipertahankan karena SalePrice merupakan atribut target yang tidak boleh dihapus. Setelah proses ini, shape data menjadi (1460, 232).

Selanjutnya, PCA diterapkan pada 230 fitur (di luar Id dan SalePrice) dengan target mempertahankan 95% variansi data.




*Gambar 5. Explained variance ratio PCA*

Hasilnya, 230 fitur berhasil direduksi menjadi 65 komponen utama yang tetap menjelaskan 95% variansi data, atau berkurang sekitar 72% dari jumlah fitur semula tanpa banyak kehilangan informasi.

**4. Ringkasan Dataset Akhir**

Berikut ringkasan perubahan ukuran dataset di setiap tahapan praproses.

| Tahap | Baris | Kolom |
|---|---|---|
| Dataset awal | 1460 | 81 |
| Setelah hapus kolom missing > 50% | 1460 | 76 |
| Setelah tangani sisa missing value (dikumpulkan sebagai csv) | 1460 | 76 |
| Setelah one-hot encoding | 1460 | 235 |
| Setelah buang atribut korelasi tinggi | 1460 | 232 |
| Setelah PCA (65 komponen + SalePrice) | 1460 | 66 |

Dataset yang dikumpulkan sebagai file csv akhir adalah hasil tahap cleaning (missing value tertangani dan outlier sudah di-capping), dengan shape (1460, 76). Tahap normalisasi, encoding, analisis korelasi, dan PCA tetap dilakukan sebagai bagian dari analisis pada notebook, menghasilkan dataset tereduksi 65 komponen PCA yang siap digunakan untuk pemodelan lebih lanjut.