

Laporan Analisis: Scrapping & Eksplorasi Data (EDA)

Dataset Florida Plant Atlas

NRP : 5054251013

Nama : Evina Fitriyani

1. Deskripsi Dataset

Dataset diambil dari situs Florida Plant Atlas (florida.plantatlas.usf.edu) lewat scraping pakai Requests dan BeautifulSoup. Total ada 1544 baris data dengan 8 kolom: `scientific_name`, `family`, `genus`, `common_name`, `status`, `url`, `panjang_nama_ilmiah`, dan `jumlah_kata_common_name`. Dua kolom terakhir itu kolom tambahan (hasil hitungan dari `scientific_name` dan `common_name`) yang dibuat karena kolom asli hasil scraping semuanya kategorikal, jadi perlu ada kolom angka buat dianalisis statistik.

2. Statistik Deskriptif

Panjang nama ilmiah rata-rata 19,9 karakter (std 5,3), paling pendek 9 karakter, paling panjang 45 karakter. Jumlah kata di common name rata-rata cuma 1,1 kata. Family paling banyak spesiesnya: CYPERACEAE (91), ASTERACEAE (77), FABACEAE (72), dari total 114 family. Status tumbuhan lebih banyak Native (507) dibanding Not Native (278).

3. Penanganan Data

Ada missing value di kolom `family` (758), `genus` (759), `common_name` (843), dan `status` (759) dari 1544 baris kemungkinan karena struktur halaman di sebagian spesies beda formatnya jadi gagal ke-scrape lengkap. Kolom `growth_habit` langsung di-drop karena isinya kosong semua. Missing value di kolom lain dibiarin aja, ga dihapus barisnya, karena kolomnya kategorikal dan ga ganggu perhitungan kolom angka.

Deteksi outlier pakai metode IQR: ketemu 97 outlier di `panjang_nama_ilmiah` dan 12 outlier di `jumlah_kata_common_name`. Ga dihapus karena itu tetep data valid (nama tumbuhan beneran), cuma emang ada yang namanya lebih panjang dari rata-rata.

4. Visualisasi dan Interpretasi

- Panjang nama ilmiah kebanyakan di 17-22 karakter, agak condong ke kanan karena ada beberapa yang jauh lebih panjang.
- Jumlah kata common name kebanyakan cuma 0-1 kata.

- Family CYPERACEAE paling dominan, status Native jauh lebih banyak dari Not Native.
- Panjang nama ilmiah dan jumlah kata common name ga ada hubungan yang jelas satu sama lain (scatter plot & heatmap nunjukkin korelasi lemah).
- Panjang nama ilmiah beda-beda tergantung family-nya (dilihat dari boxplot).

5. Kesimpulan

Dataset Florida Plant Atlas ini isinya beragam, ada 114 family berbeda dengan CYPERACEAE paling banyak, dan mayoritas tumbuhannya berstatus native di Florida. Datanya sebagian besar kategorikal, sementara dua kolom angka yang dibuat nunjukkin pola distribusi yang cukup normal walau ada beberapa outlier alami. Proses scraping berhasil dapat data dalam jumlah cukup, meski ada missing value di beberapa kolom akibat variasi struktur halaman sumbernya.