Laporan Tugas Praktikum 5 Sequential Pattern Analysis

Evina Fitriyani | NRP 5054251013

1. Dataset dan Pembersihan Data

Dataset yang dipakai adalah Online Retail dari UCI, berisi 541.909 baris transaksi toko online di Inggris dari Desember 2010 sampai Desember 2011. Dari delapan kolom yang ada, tiga yang dipakai buat sequential pattern: CustomerID sebagai pemilik sequence, InvoiceDate buat urutan waktu, dan Description sebagai nama produk.

Sebelum dipakai, data dibersihkan dulu. Baris yang CustomerID atau Description-nya kosong dibuang (135.080 baris), begitu juga invoice batal yang diawali huruf C dan baris dengan Quantity negatif atau nol (8.905 baris). Baris yang bukan produk, seperti POSTAGE dan Manual, juga dibuang (1.550 baris).

	Sebelum	Sesudah	Selisih
Jumlah baris	541.909	396.374	145.535 (26,9%)
Jumlah invoice	25.900	18.405	7.495 (28,9%)
Jumlah pelanggan	4.372	4.335	37 (0,8%)

Sebagian besar baris yang hilang karena tidak punya CustomerID, jadi jumlah pelanggannya hampir tidak berkurang. Setelah dibersihkan, ada 4.335 pelanggan dan 3.861 produk unik. Rata-rata satu pelanggan punya 4,25 invoice, tapi mediannya cuma 2 dan maksimumnya 206. Sekitar 1.500 pelanggan malah cuma punya 1 invoice. Produk yang dibeli pelanggan berbeda paling banyak ada di tabel berikut (5 teratas).

Produk	Jumlah pelanggan	Support
REGENCY CAKESTAND 3 TIER	881	0,2032
WHITE HANGING HEART T-LIGHT HOLDER	856	0,1975
PARTY BUNTING	708	0,1633
ASSORTED COLOUR BIRD ORNAMENT	678	0,1564
SET OF 3 CAKE TINS PANTRY DESIGN	640	0,1476

2. Persiapan Data

Data diurutkan berdasarkan CustomerID dan InvoiceDate. Item yang dibeli dalam satu invoice dijadikan satu itemset, lalu semua invoice milik satu pelanggan disusun jadi satu sequence dari yang paling lama sampai yang terbaru. Kalau pelanggan membeli produk yang sama lebih dari sekali, yang dihitung cuma pembelian pertamanya.

Hasilnya 4.335 sequence dengan panjang rata-rata 61,7 produk (median 35, maksimum 1.813). Library prefixspan hanya membaca urutan item, jadi item dalam satu invoice ditulis berdampingan dengan urutan abjad.

3. Penerapan Algoritma

Algoritma yang dipakai adalah PrefixSpan dengan minimum support 0,01 dari jumlah pelanggan. Artinya sebuah pola harus muncul di minimal 44 pelanggan (0,01 x 4.335 = 43,35, dibulatkan ke atas). Panjang pola dibatasi maksimal 3 produk biar prosesnya tidak terlalu lama.

Hasilnya 19.405 pola, terdiri dari 1.761 pola 1 produk, 13.503 pola 2 produk, dan 4.141 pola 3 produk. Yang dihitung sebagai pola berurutan hanya yang minimal 2 produk, yaitu 17.644 pola.

min_support	Total pola	Pola dengan panjang >= 2
0,01	19.405	17.644
0,02	2.606	1.562
0,03	958	303
0,05	291	27

Support tertinggi untuk pola berurutan cuma sekitar 0,07, jadi nilai minimumnya memang harus kecil. Kalau dinaikkan ke 0,05, polanya tinggal 27 dan terlalu sedikit buat dianalisis. Karena itu 0,01 tetap dipakai. Jumlah polanya memang banyak, tapi cukup diurutkan berdasarkan support dan diambil yang teratas.

4. Pola Berurutan dan Evaluasi

Support semua pola berada di kisaran 0,01 sampai sekitar 0,07, sedangkan confidence-nya menyebar dari sekitar 0,05 sampai 0,98. Kebanyakan pola ada di support rendah (0,01 sampai 0,02), dan makin tinggi support-nya makin sedikit polanya. Pola dengan confidence di atas 0,8 umumnya ada di support 0,01 sampai sekitar 0,04. Pola dengan support di atas 0,05 punya confidence sekitar 0,3 sampai 0,77.

Tiga pola dengan support tertinggi, diambil dari pola yang minimal 2 produk:

No	Beli dulu	Lalu beli	Jumlah pelanggan	Support	Confidence
1	PAPER CHAIN KIT 50’S CHRISTMAS	PAPER CHAIN KIT VINTAGE CHRISTMAS	301	0,0694	0,491
2	GREEN REGENCY TEACUP AND SAUCER	ROSES REGENCY TEACUP AND SAUCER	297	0,0685	0,7674
3	GREEN REGENCY	PINK REGENCY	290	0,0669	0,7494

	TEACUP AND SAUCER	TEACUP AND SAUCER			

Pola pertama muncul di 301 dari 4.335 pelanggan (6,94%), yaitu yang membeli PAPER CHAIN KIT 50’S CHRISTMAS lalu PAPER CHAIN KIT VINTAGE CHRISTMAS. Ada 613 pelanggan yang membeli versi 50’S, dan sekitar 49% dari mereka (confidence 0,4910) juga membeli versi VINTAGE. Keduanya sama-sama hiasan Natal, jadi toko bisa menawarkan varian yang lain begitu pelanggan membeli salah satunya, apalagi menjelang Natal.

Pola kedua dan ketiga sama-sama berawal dari GREEN REGENCY TEACUP AND SAUCER, yang dibeli 387 pelanggan. Dari jumlah itu, 297 orang (76,74%) juga membeli versi ROSES dan 290 orang (74,94%) membeli versi PINK. Confidence-nya tinggi, jadi cangkir seri Regency ini sepertinya dikumpulkan satu set. Toko bisa menjualnya sebagai paket warna atau menawarkan warna lain setelah pembelian pertama.

Ada satu hal yang perlu dicatat. Ketiga pola ini, bahkan semua 20 pola dengan support tertinggi, urutannya mengikuti abjad (GREEN selalu sebelum PINK dan ROSES, dan tidak ada yang kebalikannya). Ini terjadi karena item dalam satu invoice ditulis urut abjad, sehingga banyak pola kemungkinan berasal dari produk yang dibeli di invoice yang sama. Ditambah lagi, sekitar 1.500 pelanggan cuma punya satu invoice. Jadi pola ini lebih pas dibaca sebagai produk satu seri yang dibeli bersamaan atau berdekatan, belum bisa dibilang bukti kuat bahwa pelanggan membeli B di waktu yang berbeda setelah A.

5. Kesimpulan

Setelah data dibersihkan, tersisa 4.335 pelanggan, 18.405 invoice, dan 3.861 produk. PrefixSpan dengan min support 0,01 dan panjang pola maksimal 3 menghasilkan 19.405 pola, dengan 17.644 di antaranya pola berurutan (minimal 2 produk). Support tertingginya cuma 6,94%, jadi tidak ada urutan beli yang dilakukan oleh sebagian besar pelanggan.

Tiga pola teratas semuanya berasal dari produk satu seri, yaitu PAPER CHAIN KIT Natal (confidence 49%) dan cangkir REGENCY hijau ke ROSES dan PINK (confidence 75% sampai 77%). Pola ini bisa dipakai buat rekomendasi varian produk dan paket koleksi, dengan catatan sebagian polanya kemungkinan berasal dari invoice yang sama.